

Contents

学习小波有用吗？——完美重构约束使可学习小波在低剂量 CT 去噪中产生收益	1
摘要	1
1. 引言	1
2. 相关工作	2
3. 方法	3
4. 实验设置	4
5. 实验	5
6. 讨论与局限	8
7. 结论	8
可复现性	8
参考文献	8
附录 A: 复现步骤	9

学习小波有用吗？——完美重构约束使可学习小波在低剂量 **CT** 去噪中产生收益

中文对照版 — 2026-09-14

本文件仅供审阅。投稿使用英文版 `conference_paper.md` (EI 会议要求英文)。中文版与英文版内容一一对应，所有数字均相同，不单独修改。

目标会议: ICIP 2027 (5 页正文 + 第 6 页参考文献) / ICME 2027 (6 页) / EUSIPCO 2027 (共 5 页)

摘要

让小波变换可学习，是小波域图像去噪的一个自然延伸。我们证明：在低剂量 **CT** 上，这一延伸默认是失败的——无约束的可学习分析/合成滤波器对在训练中会偏离可逆性，所得网络的表现不比固定的 **Haar** 基更好 (-0.03 dB, $p = 0.11$, 95% 置信区间跨零)。我们追溯到其原因：训练后变换的重构误差达到 **12–15%**。并进一步证明这是因果而非仅仅相关——向完美重构臂注入一个同样量级的受控误差，会把它退化到固定 **Haar** 的水平。

把完美重构由结构保证——即把小波参数化为提升格式，使逆变换复用正向滤波器——之后，学习才产生收益：相对无约束学习 **+0.30 dB** ($p = 0.0005$)，相对固定 **Haar +0.27 dB** ($p = 0.0004$)，且在两个数据划分上一致。

最终网络仅有 **2,159** 个参数，在 AAPM-Mayo 2016 上达到 **31.97 dB**，与同等协议下训练的 **RED-CNN** 基线相差 1.0 dB 以内，而参数量少 **857** 倍。

关键词：低剂量 **CT**、图像去噪、可学习小波、提升格式、完美重构、可逆性

1. 引言

低剂量 **CT** (**LDCT**) 降低了辐射暴露，代价是噪声升高。**RED-CNN** [1] 这类深度去噪网络有效，但参数量大 (约 10 量级)，这限制了它在基层医疗机构常见的低资源工作站上的部署。因此轻量模型是有吸

引力的。

小波域处理是分离噪声与结构的经典手段，近期工作进一步让小波本身可学习，以适配特定模态与剂量 [17]–[22]。本文问一个简单的问题：

让小波可学习，真的有用吗？

我们通过一个受控三臂实验得到的答案是：单靠它没用。无约束的可学习分析/合成滤波器对的表现，与固定 Haar 基在统计上无法区分（见 §5.2）。原因不是“自适应没用”，而是学习摧毁了变换自身的可逆性：训练后，分析-合成闭环误差达到信号范数的 **12–15%**，网络不得不把容量花在补偿一个本不该由它建模的损失上。

随后我们说明，这个问题可以通过结构设计解决。把小波参数化为提升格式（lifting scheme）[23], [24]——逆变换不是另一组参数，而是把正向的预测/更新滤波器反向应用——无论滤波器学到什么，可逆性都有保证。加上这一约束后，学习终于产生了收益：相对无约束学习 +0.30 dB，相对固定 Haar +0.27 dB，两者都高度显著。

贡献

1. 一个负结果：无约束的可学习小波在 LDCT 去噪上，相对固定 Haar 基没有任何收益。
2. 一个机制，通过干预确立：失效的原因是可逆性的丧失。向 **PR** 臂注入一个同样量级的受控闭环误差，会把它退化到固定 Haar 水平——单调且显著（ $n = 5$ 种子，每一档 $p < 0.007$ ）。先前的可逆小波去噪方法观察不到这一状态，因为它们的设计使它不可达。
3. 一条实用警示：结构性完美重构保证在浮点下不会自动兑现。对提升 taps 做有界化才能让它成立——不有界化时闭环误差从 3.6×10^{-4} 恶化到 5.2×10^{-4} ，这一点在可逆网络文献中没有被报告过。
4. 一个 **2,159** 参数的网络，接近已发表基线的水平。

2. 相关工作

2.1 低剂量 CT 去噪

RED-CNN [1] 这类卷积编解码器奠定了该领域，随后是对抗方法 [2], [3]，以及更近期的 Transformer 与扩散模型方法 [4]–[11]。这些方法提升了保真度，但参数量在 10^8 – 10^9 。另一条路线转而追求效率：MLAR-UNet [13]、CT-Mamba [15]、AMFA-Net [16]、FMDNet [14] 与 MobileMamba-UNet [12] 都以远低的代价报告了有竞争力的结果，其中最后一个同样在小波域工作。我们认同效率目标，但问的是另一个问题——不是去噪器能有多小，而是让变换本身可学习到底有没有帮助。

2.2 小波域与多分辨率去噪

小波收缩（wavelet shrinkage）[27], [28] 通过阈值化子带系数来分离噪声与结构。多级小波 CNN [17], [18] 把这一结构重新引入深度网络，近期 LDCT 方法把小波与扩散模型 [11] 或状态空间模型 [12] 结合。在这些工作中，变换都是固定算子，可学习容量位于其外围网络。

2.3 可学习变换与可逆性

另一条路线让变换本身可学习。LINN [19] 在一个固定的非抽取 Haar 变换周围学习提升格式的预测/更新步骤；WINNet [20] 更进一步，连切分算子本身也学习，并用 Cayley 变换约束其正交性，从而使完美重构由构造保持。两者都把可逆性构建进了架构。经典滤波器组理论 [25], [26] 给出完美重构条件，提升格式 [23], [24] 是按设计满足这些条件的标准构造；正交性则另被用于改善 CNN 的优化条件 [30]。

2.4 最接近的先行结果（正面处理）

WINNet 的 Table II 消融在自然图像 AWGN 去噪上比较了带/不带抽取的 Haar、多种尺寸的 DCT、以及 Cayley 学到的算子，结论是学到的算子与固定 **DCT** 表现相近 —— 因此他们默认改用固定算子。

这与我们的负结果表面相似，所以我们在这里正面处理，而不是留给审稿人去发现。有两点区别很重要。第一，他们的学到算子被约束为正交，因此完美重构始终成立：他们的比较是在两个可逆变换之间，而我们的是在可逆与不可逆之间 —— 我们所诊断的那个失效状态，在他们的设计中根本不可达，而且两篇论文都从未报告过任何闭环误差测量。第二，他们的工作是“挑默认值”的消融，没有显著性检验；而我们的是五种子配对检验，带置信区间。

2.5 我们的定位

我们既没有提出新的小波，也没有提出新的架构 —— §3.2 的提升构造是 LINN 和 WINNet 的，而且 WINNet 已经在保持完美重构的前提下学习滤波器 taps。真正新的是那个缺失的对照。

先前的可逆小波去噪方法假设了结构性可逆，从未检验其缺失，因此无法报告“没有它会怎样”。让可学习变换的可逆性变成可选项、固定容量与训练协议、并测量其后果 —— 以及解释它的那个横跨六个数量级的闭环误差差距 —— 才是本文的贡献。§5.2 会再回到与 WINNet 消融之间的残余张力。

3. 方法

3.1 总体结构

网络在小波域中工作：

含噪 CT $\mathbf{x}$

↓ PR-LWT 分解（2 级，7 个子带）

↓ 逐子带残差预测： $\mathbf{b} = \text{head_b}(\text{band_b})$

↓ 清理后的子带： $\text{clean_b} = \text{band_b} - \mathbf{b}$

↓ PR-LWT 重建

去噪结果 $\hat{\mathbf{x}}$

其中 $\mathbf{x}$ 为含噪输入， $\mathbf{b}$ 为逐子带的残差预测。2 级分解得到七个子带：{LL, LH, HL, HH, LH, HL, HH}。

3.2 PR-LWT：可完美重构的可学习小波

我们使用提升格式。一维情形下，按奇偶切分：

分解： $\mathbf{d} = \mathbf{x}_o - \mathbf{P}(\mathbf{x}_e)$ $\mathbf{s} = \mathbf{x}_e + \mathbf{U}(\mathbf{d})$

合成： $\mathbf{x}_e = \mathbf{s} - \mathbf{U}(\mathbf{d})$ $\mathbf{x}_o = \mathbf{d} + \mathbf{P}(\mathbf{x}_e)$

关键在于：合成复用与分解相同的 $\mathbf{P}$ 和 $\mathbf{U}$ 。因此可逆性是结构的性质，而非所学数值的性质：对任意 $\mathbf{P}$ 、 $\mathbf{U}$ ， $\text{reconstruct}(\text{decompose}(\mathbf{x})) = \mathbf{x}$ 在浮点精度内恒成立。

二维变换是可分离的（先沿高度、再沿宽度做提升）。我们初始化 $\mathbf{P} = [0,1,0]$ （恒等预测）与 $\mathbf{U} = [0,0.5,0]$ ，再施加 $\sqrt{2}$ 的输出缩放，使初始化严格等于正交归一 **Haar**（四个子带均已核验到 2×10^{-6} ）。

参数有界化是必要的，不是可选的。我们参数化为

$\mathbf{P} = \mathbf{P}_{\text{init}} + 0.5 \cdot \tanh(\mathbf{P})$ $\mathbf{U} = \mathbf{U}_{\text{init}} + 0.5 \cdot \tanh(\mathbf{U})$

不加这个约束时，taps 会漂移到 $|P| = 5$ ，此时 float32 下的闭环误差从 3.6×10^{-5} 恶化到 5.2×10^{-5} 。完美重构在精确算术下无条件成立；有界化才是让它在 **float32** 下可用的东西。

参数量：2 级 $\times$ 2 方向 $\times$ 2 滤波器 $\times$ 3 taps = **24** 个。

3.3 子带去噪头

每个子带由一个轻量头处理（conv3 $\times$ 3 $\rightarrow$ ReLU $\rightarrow$ conv3 $\times$ 3，内部 16 通道），预测该子带的残差（有符号，末层无激活）。七个头共 2,135 个参数；完整网络共 **2,159** 个。

3.4 训练

损失：预测与真值之间的 L1。Adam，学习率 10^{-3} ，30 轮，128 $\times$ 128 随机图块，批大小 8。

4. 实验设置

4.1 数据

AAPM-Mayo 2016 低剂量 CT 挑战赛 [31], [32]，3 mm B30 配对子集：10 位患者，2,378 对四分之一剂量 / 全剂量 512 $\times$ 512 切片。切片按 ImagePositionPatient[2]（z 位置）配对；不能按文件名配对，因为两侧的切片序号字段完全相同。

4.2 评测口径

AAPM 从未定义过 PSNR 口径（其官方指标是放射科医师阅片评分），该数据集上至少并存五种互不兼容的约定。我们采用 **RED-CNN / CTformer** 谱系的口径，该口径被六个公开仓库逐字沿用：

预处理 $\mathbf{x} = (\text{HU} + 1024) / 4096$ （不裁剪）
评测 反归一化回 HU；预测与参考同时 clip 到 $[-160, 240]$
PSNR = $10 \cdot \log_{10}(400^2 / \text{MSE_HU})$ ，data_range = 400
SSIM 按 SSInyu/RED-CNN 的 measure.py
聚合 逐切片算指标后取平均

我们的实现逐位复现了独立测量的 identity 基线（L506 29.2489、L067 26.5576、合并 27.8630）。

4.3 数据划分

采用两个按患者的划分以证明稳健性：

划分	训练	验证	测试
S1 （主）	7 患者（1,600 张）	L291	L506 + L067（435 张）
S2 （对齐文献）	8 患者（1,943 张）	L067	仅 L506 （211 张）

S2 对齐已发表工作的惯例，使数字可直接比较。

4.4 地板：什么都不做

identity（输出 = 输入）是每个模型必须超过的地板。全部十位患者按 PSNR 排序：

患者	n	identity PSNR	SSIM	出现在
L143	234	25.4991	0.7643	训练
L310	214	26.2577	0.7273	训练
L067	224	26.5576	0.7987	S1 测试 / S2 验证
L109	128	26.6052	0.8165	训练
L096	330	26.9097	0.7853	训练
L291	343	26.9805	0.8088	S1 验证 / S2 训练
L333	244	27.2508	0.8305	训练
L192	240	28.2896	0.8344	训练
L286	210	29.1479	0.8103	训练
L506	211	29.2489	0.8759	测试（两者）
<i>S1 测试合并</i>	<i>435</i>	<i>27.8630</i>	<i>0.8361</i>	
<i>S2 测试（L506）</i>	<i>211</i>	<i>29.2489</i>	<i>0.8759</i>	

患者间跨度（**25.50 – 29.25 dB**，**3.75 dB** 的区间）大于我们报告的任何一个效应，因此所有结果一律逐患者报告。

5. 实验

5.1 主结果

划分	方法	参数量	PSNR	SSIM
S1	identity	—	27.8630	0.8361
S1	PR-LWT （本文）	2,159	30.8314 ± 0.0815	—
S1	RED-CNN [1] （本文复现，同划分）	1,848,865	31.8310	0.8824
S2	identity (L506)	—	29.2489	0.8759
S2	PR-LWT （本文）	2,159	31.9731 ± 0.0787	—
S2	RED-CNN [1] （本文复现，同划分）	1,848,865	32.9471	0.9090
S2	RED-CNN [1] （文献报告值）	~10	32.93	—
S2	CTformer [4]（文献报告值）	~1.4×10	32.9	—

标” 本文复现” 的基线，是我们用完全相同的协议自己训练的 —— 相同划分、相同图块尺寸、批大小、优化器、调度与评测 —— 因此对比不再依赖于复现他人设定。由此有两点观察。

第一，这是对我们协议的一次独立检验：在对齐文献的 S2 划分上，我们复现的 RED-CNN 在 L506 上达到 **32.9471 dB**，与独立发表的、同一患者的 32.93 dB 相差 **0.02 dB**。也就是说，我们的实现与评测口径是真正复现了参考结果，而不只是” 看起来接近”。

第二，在这个匹配的对比下，PR-LWT 在参数量少 **857** 倍 (2,159 vs 1,848,865) 的条件下，与 RED-CNN 相差 **0.97 dB** (S2) 与 **1.00 dB** (S1)。我们明确写出：**PR-LWT** 在 **PSNR** 上并未击败 **RED-CNN**；本文检验的主张是是什么让可学习变换产生帮助，而不是达到最优性能。

5.2 消融：可逆性是不是关键？

三条臂，彼此只在所用小波上不同：

臂	小波	可学习	可逆性保证	小波参数
pr	提升格式		(结构保证)	24
unconstrained	分离的正/逆滤波器			64
fixed	正交归一 Haar			0

三条臂回答两个不同的问题：**pr** vs **unconstrained** 隔离可逆性的作用；**pr** vs **fixed** 隔离可学习性的作用。

结果（跨种子均值 $\pm$ 标准差；配对 t 检验，以训练种子为独立单元）：

划分	臂	PSNR	n
S1	pr	30.8314 $\pm$ 0.0815	5
S1	unconstrained	30.5341 $\pm$ 0.0305	5
S1	fixed	30.5591 $\pm$ 0.0256	5
S2	pr	31.9731 $\pm$ 0.0787	3
S2	unconstrained	31.6788 $\pm$ 0.0307	3
S2	fixed	31.6936 $\pm$ 0.0394	3

配对比较：

划分	比较	Δ (dB)	t	p	95% CI
S1	pr — unconstrained	+0.2973	10.44	0.0005	[+0.218, +0.376]
S1	pr — fixed	+0.2723	10.68	0.0004	[+0.202, +0.343]
S1	unconstrained — fixed	-0.0251	-2.02	0.113	[-0.060, +0.009]
S2	pr — unconstrained	+0.2942	7.92	0.016	[+0.134, +0.454]
S2	pr — fixed	+0.2794	10.95	0.008	[+0.170, +0.389]
S2	unconstrained — fixed	-0.0148	-1.25	0.337	[-0.066, +0.036]

三个结论，在两个划分上完全一致：

1. 施加完美重构约束，使可学习小波显著优于固定 **Haar** (+0.27 dB, $p < 0.001$)。

2. 它同时显著优于无约束学习 (+0.30 dB, $p < 0.001$)。
3. 无约束学习与固定 **Haar** 无法区分 ($p = 0.11 / 0.34$; 两个划分上置信区间均跨零)。

结论 3 是关键。它不是统计功效不足的产物，因为同一个实验能在 $p < 0.001$ 下分辨出 +0.27 dB 的差异。无约束学习确实什么都没换来。

关于分析单元。测试集包含 435 张 (S1) / 211 张 (S2) 切片，但它们来自仅仅 2 位 / 1 位患者。同一患者的相邻切片高度相关，若把切片当作独立样本，显著性会被夸大数个数量级。因此上述所有检验都以训练种子为独立单元。这是刻意保守的做法。

与 **WINNet** 切分算子消融的关系。WINNet [20] 在一个表面相似的比较上给出了相反的结论：其用正交约束学习到的切分算子，在自然图像 AWGN 去噪上与固定 DCT 表现相当，于是他们默认采用了固定算子。我们的设定在多个维度上同时不同——任务 (LDCT vs 自然图像 AWGN)、变换族 (一个以 **Haar** 为初始化的 2 级提升参数化，学习是从固定基线出发离开，而不是在匹配尺寸的所有正交矩阵中搜索)、以及评测 (五种子配对检验带置信区间 vs 挑默认值的消融)。仅凭已发表的数字，我们无法把这一分歧归因于其中任何单一因素，因此我们把它标注出来，而不声称一个一般性结论。这个实验真正确立的结论更窄，我们相信也稳健：在本架构与任务内，完美重构约束才是让可学习性产生收益的原因。

5.3 机制：无约束学习到底做了什么

我们测量训练完成后的变换的分析-合成闭环误差，取每个种子的最终 checkpoint (下表中的数据见左侧图 (a); 图 (b) 是下文描述的干预实验)：

臂	小波参数	闭环误差 (相对 L2), S1	S2
pr	24	1.62e-07	1.65e-07
fixed	0	1.64e-07	1.64e-07
unconstrained	64	1.25e-01	1.45e-01

无约束学习把变换推到了一个每次正-逆往返丢失 **12–15%** 信号的状态 (S1 逐种子范围 0.11–0.15)，而两个可逆臂则停在 **1.6×10^{-7}** (float32 极限)：相差六个数量级。网络于是必须一边去噪、一边补偿自己的变换。

上面的比较是相关性的。无约束臂既丧失了可逆性、又表现如固定 Haar，但这本身不足以说明前者导致了后者。因此我们直接做干预：固定架构、容量与训练协议不变，向 **PR** 臂注入一个受控的闭环误差——让它的合成步使用 $(1 - \epsilon) \cdot U$ 而分解仍用 U ，从而在隔离条件下精确复现无约束臂自发产生的那个缺陷：

注入	实测闭环	测试 PSNR (S1)	相对 $\epsilon=0$	配对 p
0 (对照)	1.6e-07	30.8314 $\pm$ 0.0815	—	—
0.111	5.5e-02	30.7142 $\pm$ 0.0508	-0.117	0.0067
0.222	8.7e-02	30.5500 $\pm$ 0.0618	-0.281	0.0010
0.444	1.2e-01	30.2850 $\pm$ 0.0459	-0.546	<0.0001

性能随注入误差单调下降，且每一档都显著 (配对 t 检验，独立单元 = 训练种子, $n = 5$)。在 **8.7%** 闭环误差处，PR 臂落到 **30.5500 dB**——正是固定 Haar 的水平 (30.5591)，也就是一个“什么都没学到”的臂的表现。因此这个干预在因果层面支持了机制：这个量级的误差不只是与失效相关，它足以造成失效。

诚实边界。这条剂量-响应曲线比跨臂比较更陡：在 11.8% 误差处，注入臂达到 30.2850 dB，低于无约束臂（30.5341）也低于固定 Haar（30.5591）。无约束臂的失配同时存在于它的分析与合成两组滤波器中，而我们的注入只扰动合成侧——两种缺陷量级相同、结构不同。因此我们声称的是同量级下的充分性，而不是精确复现无约束臂的误差。

PR-LWT 在保持完全自适应的同时，把闭环误差维持在 float32 极限。这就是全部机制。

6. 讨论与局限

为什么我们不声称“无损”。完美重构只保证系数未被修改时的往返。去噪按其定义就是要修改系数，因此完美重构并不蕴含一个无损的去噪器。我们的主张更窄也更精确：完美重构约束移除了“变换本身”这个网络不得不建模的误差来源，而这正是使自适应能够产生收益的原因。

局限。

1. 单一数据集（AAPM-Mayo）。在其它 CT 数据上的泛化未经检验——其中 LoDoPaB-CT [33] 我们特别说明：它是重建基准（其 observation 是正弦图），若不先做 FBP 重建，无法直接用作零样本去噪测试。
 2. 测试队列小（S1 两位患者，S2 一位）。这正是我们逐患者报告、并以种子为分析单元的原因。
 3. 同划分基线只覆盖 **RED-CNN**。RED-CNN 由我们在自己的划分与协议下重新训练 (§5.1)；CTformer 与其余方法仍引自文献，其训练集差异依然适用。重新训练更多基线超出本文范围。
 4. 注入的缺陷比真实的那个更简单。我们只扰动合成滤波器，而无约束臂的两组滤波器组是各自独立漂移的。干预确立的是同量级下的充分性 (§5.3)，而不是对该臂误差的精确复现。
 5. 未做下游任务验证（如分割）。
-

7. 结论

我们问：让小波可学习，对 LDCT 去噪有帮助吗？答案是：默认没有——无约束的可学习小波表现与固定 Haar 基完全一样，因为学习摧毁了变换的可逆性。把可逆性变成本身由结构保证——通过一个逆变换复用正向滤波器的提升格式——才让自适应产生收益，而网络只有 2,159 个参数。

这个教训可以推广到本任务之外：当一个被学习的部件理应可逆时，可逆性应当是结构性的，而不是寄希望于它自己成立。

可复现性

本文所有数字来自 24 组已完成的运行（3 臂 $\times$ {5, 3} 种子 $\times$ 2 划分），加上两条 RED-CNN 基线与 identity 基线。每次运行把完整配置（数据量、参数构成、学习率衰减点、代码版本）写入 `config.json`，逐切片指标写入 `results.json`。闭环误差测量来自 `verify_roundtrip.py`。代码与配置将在录用后发布。

参考文献

与英文版完全一致，33 条，全部经 Crossref / DataCite 一手元数据核验。此处不重复列写，请见 `conference_paper.md` 或 `latex/main.tex`。

附录 A: 复现步骤

```
cd LDCT
python data/prepare_aapm.py                # DICOM -> HDF5
python experiments/train.py --baseline-only # identity 地板
for w in pr unconstrained fixed; do
    python experiments/train.py --tag ${w}_s0 --wavelet $w \
        --epochs 30 --patch 128 --batch-size 8 --seed 0
done
python experiments/analyze_arms.py --prefix w3_    # S1
python experiments/analyze_arms.py --prefix lit_   # S2
```

每次运行的完整配置在 `experiments/runs/<tag>/config.json`; 逐样本指标在同目录 `results.json`。